

Báo Cáo Nghiên Cứu: Tích Hợp Cơ Chế Attention Vào Mô Hình EDL-ECC

Ngày 13 tháng 8 năm 2026

1 Cơ sở lý thuyết & Động lực nghiên cứu

1.1 Cơ chế Label Attention trong Phân loại Đa nhãn (UCLAF Framework — IJCAI 2025)

Mô hình UCLAF đề xuất mô-đun *Label Attention Aware Network* (LAN) nhằm giải quyết sự trùng lặp và tương quan phức tạp giữa các nhãn. Thay vì buộc tất cả các nhãn dùng chung một vector biểu diễn toàn cục, LAN học biểu diễn ngữ nghĩa riêng cho từng nhãn l_k dựa trên tương tác *additive attention* với các đặc trưng đầu vào f_i

$$s_{ik} = v_b^\top \tanh(W_b[l_k; f_i]) \quad (1)$$

Điểm số s_{ik} được chuẩn hóa bằng hàm Softmax để thu được trọng số attention β_{ik} , từ đó tổng hợp thành vector ngữ nghĩa đặc trưng cho từng nhãn

$$c_k = \sum_{i=1}^N \beta_{ik} f_i \quad (2)$$

Kết quả thực nghiệm kiểm chứng (*Ablation Study*) cho thấy việc bổ sung LAN giúp metric $P@1$ tăng từ 85.30% lên 85.58% trên tập AAPD và từ 84.55% lên 85.42% trên tập EURLex. Khi kết hợp LAN với *Correlation Aware Contrastive Learning* (CACL), hiệu năng $P@1$ đạt mức SOTA tương ứng là 86.69% và 87.32%.

1.2 Lý thuyết “SLIC-MLIC Learning Game” (MLIC Survey — 2026)

Khảo sát toàn diện về phân loại ảnh đa nhãn (MLIC) chỉ ra một hiện tượng lý thuyết quan trọng: khi sử dụng biểu diễn toàn cục (*global representation*), mô hình gặp xung đột tối ưu hóa giữa việc phân tách các bộ phân loại (cần thiết cho ảnh đơn nhãn - SLIC) và việc kéo chúng lại gần nhau (cần thiết cho ảnh đa nhãn - MLIC). Việc ứng dụng Attention để tạo ra các biểu diễn cục bộ/đặc trưng theo nhãn (*label-specific representation*) giúp triệt tiêu xung đột này. Lý thuyết này giải thích vì sao các phương pháp phân rã bài toán (như RAKEL) hay các kiến trúc Attention lại vượt trội hơn các chuỗi phân loại toàn cục trên dữ liệu phức tạp.

2 Hạn chế của kiến trúc EDL-ECC hiện tại

Mô hình *Evidential Classifier Chains* (EDL-ECC) hiện tại sử dụng các mạng MLP thuần túy cho từng bộ phân loại trong chuỗi. Việc truyền thông tin giữa các bước được thực hiện qua phép nối ghép đơn giản (*concatenation*):

$$x_k^{\text{input}} = [x_{\text{gốc}} ; (1 - u_{1..k-1}) \odot p_{1..k-1}] \quad (3)$$

Kiến trúc này tồn tại hai hạn chế cốt lõi:

- **Xử lý đặc trưng đồng nhất:** Bộ phân loại MLP xử lý mọi chiều không gian đặc trưng như nhau, thiếu cơ chế tự động tập trung vào các vùng/chiều đặc trưng quan trọng đối với nhãn thứ k .
- **Lan truyền thông tin thiếu ngữ nghĩa:** Việc gating nhãn tiền nhiệm chỉ dựa vào độ tin cậy $(1 - u)$ mà chưa đánh giá được mức độ liên quan ngữ nghĩa (*semantic relevance*) giữa các nhãn đã dự đoán $\{1, \dots, k - 1\}$ và nhãn hiện tại k .

3 Đề xuất cải tiến: Uncertainty-Weighted Label Attention Propagation


Để khắc phục các hạn chế trên, kiến trúc đề xuất thay thế phép nối thô bằng cơ chế **Cross-Attention tích hợp Trọng số Bất định Evidential** ở bước thứ k :

- **Query (Q_k):** Vector đại diện cho nhãn hiện tại k đang cần dự đoán (hoặc vector đặc trưng $x_{\text{gốc}}$ sau khi chiếu không gian).
- **Key (K) / Value (V):** Tập hợp trạng thái các nhãn đã dự đoán trước đó $\{1, \dots, k - 1\}$, được điều tiết bởi độ tin cậy $(1 - u_m)$ của EDL.

Cơ chế này kết hợp hai lớp lọc thông tin bổ trợ cho nhau:

1. **Evidential Uncertainty Gating (từ EDL):** Tự động triệt tiêu ảnh hưởng của các nhãn phía trước nếu chúng có độ bất định cao ($u_m \rightarrow 1$), ngăn chặn hiện tượng lan truyền lỗi trong chuỗi.
2. **Semantic Relevance Attention (từ Attention):** Đo lường mức độ tương quan ngữ nghĩa giữa nhãn k và các nhãn $\{1, \dots, k - 1\}$, ưu tiên khai thác thông tin từ các nhãn thực sự có liên quan.

1) EDL-ECC Hiện tại:



2) EDL-ECC + Attention (Đề xuất):

