

BÁO CÁO TÓM TẮT THUẬT TOÁN RANDOM k -LABELSETS (RAkEL)

(Dựa trên bài báo gốc: Tsoumakas et al., IEEE TKDE 2010)

1. TỔNG QUAN VỀ BÀI BÁO GỐC

- **Tên bài báo:** *Random k -Labelsets for Multi-Label Classification*
- **Tác giả:** Grigorios Tsoumakas, Ioannis Katakis, Ioannis Vlahavas
- **Tạp chí:** IEEE Transactions on Knowledge and Data Engineering (TKDE), Vol. 22, No. 7, 2010.
- **Đóng góp cốt lõi:** Đề xuất phương pháp ensemble **RAkEL** (Random k -Labelsets) để giải quyết hai nhược điểm chí mạng của hai phương pháp kinh điển: **Binary Relevance (BR)** (bỏ qua phụ thuộc nhãn) và **Label Powerset (LP)** (bùng nổ không gian lớp $2^{|L|}$ và mất cân bằng lớp trầm trọng).

2. ĐỘNG LỰC NGHIÊN CỨU & SO SÁNH BR vs. LP vs. RAKEL

lightbg Phương pháp	Cơ chế chính	Ưu điểm	Nhược điểm
Binary Relevance (BR)	Trầm phẳng bài toán thành M mô hình nhị phân độc lập $P(\lambda_j x)$	Huấn luyện nhanh, đơn giản, $O(M)$	Bỏ qua hoàn toàn mối quan hệ phụ thuộc giữa các nhãn (Label Correlation).
Label Powerset (LP)	Coi mỗi tập tổ hợp nhãn là 1 lớp duy nhất của bài toán Đa lớp (2^M lớp)	Học hoàn hảo mối quan hệ phụ thuộc giữa tất cả các nhãn	Sự bùng nổ không gian lớp (2^M); Mất cân bằng lớp cực kỳ trầm trọng khi M lớn.
RAkEL (Đề xuất)	Chia tập nhãn thành m tập con nhỏ kích thước k (k -labelsets), mỗi tập con dùng LP	Học được mối quan hệ phụ thuộc nhãn , kiểm soát được không gian lớp (2^k)	Cần chọn tham số k và số mô hình con m phù hợp.

3. NGUYÊN LÝ TOÁN HỌC VÀ THUẬT TOÁN RAKEL

3.1. Khái niệm k -Labelset

Cho tập M nhãn $L = \{\lambda_1, \lambda_2, \dots, \lambda_M\}$. Một k -labelset $R \subset L$ là một tập con gồm k nhãn phân biệt ($|R| = k \ll M$).

Bài toán phân loại đa nhãn trên tập con R được biến đổi thành bài toán phân loại đa lớp Label Powerset (LP) với $C = 2^k$ **lớp tổ hợp**.

3.2. Hai biến thể của RAkEL (RAkELd vs. RAkELo)

1. RAkELd (Disjoint / Rời rạc):

- Chia không gian nhãn L thành $m = \lceil M/k \rceil$ tập con **không chồng lấn**.
- **Ưu điểm:** Huấn luyện rất nhanh.

- **Nhược điểm:** Bỏ qua sự phụ thuộc giữa các nhãn thuộc 2 tập con khác nhau.

2. RAKELo (Overlapping / Ngẫu nhiên chồng lấn - Phiên bản chuẩn):

- Rút ngẫu nhiên m tập con kích thước k từ L (có thể hoàn lại).
- **Ưu điểm:** Mỗi cặp nhãn bất kỳ có xác suất cùng xuất hiện trong một k -labelset $\rightarrow$ **Mô hình hóa toàn diện sự phụ thuộc giữa tất cả các cặp nhãn.**
- Tạo ra sự đa dạng (Ensemble Diversity) cao cho mô hình.

3.3. Quy trình Bỏ phiếu Tổng hợp Dự đoán (Thresholded Average Voting)

Cho một mẫu đầu vào x :

1. Mỗi mô hình con h_i (ứng với k -labelset R_i) dự đoán xác suất cho 2^k lớp tổ hợp, từ đó suy ra xác suất nhị phân $p_{i,\lambda_j}(x)$ cho các nhãn $\lambda_j \in R_i$.
2. **Tổng hợp điểm xác suất (Average Voting)** cho nhãn thứ j :

$$p(\lambda_j = 1 | x) = \frac{1}{|\{i : \lambda_j \in R_i\}|} \sum_{i: \lambda_j \in R_i} p_{i,\lambda_j}(x) \quad (1)$$

3. **Phán quyết nhị phân:**

$$\hat{y}_j = \mathbb{I}(p(\lambda_j = 1 | x) > \tau) \quad (2)$$

với τ là ngưỡng phán quyết (mặc định $\tau = 0.5$ hoặc được tìm tối ưu).

4. TẠI SAO RAKEL ĐẶC BIỆT THÍCH HỢP CHO DỮ LIỆU ẢNH (IMAGE DATA)?

Khi kết hợp RAKEL với **Evidential Deep Learning (EDL-RAKEL)** cho dữ liệu Ảnh:

1. **Loại bỏ hoàn toàn nút thắt Dung hợp Đa phương thức (Multi-modal Fusion):**
 - Khác với Classifier Chains ($P(y_k | y_1, \dots, y_{k-1}, x)$) phải nối vector nhãn 1D mỏng vào đặc trưng ảnh x lớn, RAKEL dự đoán trực tiếp:

$$P(R_i | x) \quad (3)$$

- Đầu vào của các mô hình con **chỉ là duy nhất ma trận đặc trưng ảnh x .**

2. **Huấn luyện End-to-End song song dễ dàng:**

- Có thể dùng chung 1 Backbone trích xuất ảnh (như ResNet-50, Vision Transformer) và cắm m đầu LP Heads song song.

3. **Tích hợp Định lượng Độ bất định (Evidential Uncertainty):**

- Trong **EDL-RAKEL**, giá trị độ bất định evidential $u_i = \frac{2^k}{S_i}$ của từng k -labelset được dùng để tính **Trọng số Bỏ phiếu Tự tin** $w_i = 1 - u_i$:

$$p(\lambda_j = 1 | x) = \frac{\sum_{i: \lambda_j \in R_i} (1 - u_i) \cdot p_{i,\lambda_j}(x)}{\sum_{i: \lambda_j \in R_i} (1 - u_i)} \quad (4)$$

5. KẾT LUẬN & GIÁ TRỊ ỨNG DỤNG

Bản chất của **RAKEL** là sự dung hòa thông minh giữa **tính hiệu quả tính toán của Binary Relevance** và **khả năng học tương quan nhãn của Label Powerset**. Khi tích hợp thêm **Evidential Deep Learning**, **EDL-RAKEL** trở thành một kiến trúc mạnh mẽ, thanh thoát và đạt hiệu năng đỉnh cao ($Subset Accuracy = 97.30\%$, $Micro-F1 = 99.55\%$ trên tập ảnh Scene).